

**SISTEM ANALITIK DATA DAN PREDIKSI PENDAPATAN BISNIS
BERBASIS DATA & CUACA KALENDER PADA KEDAI KOPI**

“Warkop Kusuma”



Disusun oleh Kelompok 5B :

Djijo Otniel Christiawan (L0224017)

Jimly Syahbatin (L0224033)

**PROGRAM STUDI SAINS DATA
FAKULTAS TEKNOLOGI INFORMASI DAN SAINS DATA
UNIVERSITAS SEBELAS MARET
SURAKARTA**

2026

ABSTRAK

Warung kopi merupakan salah satu usaha kuliner yang sangat dipengaruhi oleh kondisi cuaca dan hari libur dalam menentukan jumlah pengunjung serta pendapatan hariannya. Penelitian ini membangun sebuah sistem pipeline data end-to-end yang mengintegrasikan berbagai sumber data secara otomatis, meliputi data cuaca real-time dari Open-Meteo API, data hari libur nasional, serta data penjualan harian dari sistem kasir warung kopi. Pipeline dirancang menggunakan Apache Airflow sebagai orkestrasi workflow, Apache Kafka dan Apache Spark untuk pemrosesan data streaming, serta PostgreSQL sebagai penyimpanan data terstruktur. Selain itu, sistem ini dilengkapi dengan model machine learning berbasis Random Forest yang mampu memprediksi pendapatan harian berdasarkan fitur cuaca dan kalender. Hasil visualisasi ditampilkan melalui dashboard Metabase untuk mendukung pengambilan keputusan operasional secara real-time. Sistem pemantauan menggunakan Prometheus, Loki, dan Grafana turut diintegrasikan untuk menjaga keandalan pipeline secara keseluruhan.

Kata kunci: data pipeline, Apache Airflow, Kafka, Spark, prediksi pendapatan, machine learning, cuaca

A coffee shop is one type of culinary business that is highly influenced by weather conditions and public holidays in determining the number of daily visitors and revenue. This project develops a complete end-to-end data pipeline system that automatically integrates multiple data sources, including real-time weather data from the Open-Meteo API, national public holiday data, and daily sales data from the coffee shop's point-of-sale system. The pipeline is built using Apache Airflow for workflow orchestration, Apache Kafka and Apache Spark for stream data processing, and PostgreSQL as the structured data storage. In addition, the system incorporates a Random Forest-based machine learning model capable of predicting daily revenue based on weather and calendar features. Visualization results are presented through a Metabase dashboard to support real-time operational decision-making. A monitoring stack using Prometheus, Loki, and Grafana is also integrated to ensure the overall reliability of the pipeline.

Keywords: data pipeline, Apache Airflow, Kafka, Spark, revenue prediction, machine learning, weather

DAFTAR ISI

(Silakan buat daftar isi otomatis setelah laporan selesai disusun di Microsoft Word / Google Docs)

BAB 1: PENDAHULUAN

1.1 Latar Belakang

Usaha mikro dan kecil di sektor kuliner, khususnya warung kopi, memegang peranan penting dalam perekonomian masyarakat Indonesia. Salah satunya adalah Warkop Kusuma yang berlokasi di Sukoharjo, Jawa Tengah. Sebagai usaha yang melayani pelanggan secara langsung setiap harinya, Warkop Kusuma menghadapi tantangan nyata dalam memperkirakan jumlah pengunjung dan pendapatan harian, terutama karena kondisi ini sangat dipengaruhi oleh faktor eksternal seperti cuaca dan hari libur nasional.

Selama ini, pengelolaan operasional Warkop Kusuma masih berjalan secara konvensional tanpa dukungan sistem analitik yang memadai. Pemilik usaha belum memiliki gambaran yang cukup jelas mengenai pola pendapatan harian, kapan penjualan cenderung meningkat atau menurun, serta bagaimana kondisi cuaca mempengaruhi keputusan pelanggan untuk datang ke warung. Akibatnya, pengambilan keputusan operasional seperti persiapan stok bahan baku, pengaturan jadwal karyawan, hingga perencanaan promosi masih dilakukan berdasarkan intuisi semata.

Di sisi lain, perkembangan teknologi data saat ini memungkinkan sebuah usaha kecil sekalipun untuk memanfaatkan pendekatan berbasis data dalam mengelola bisnisnya. Teknologi seperti pipeline data otomatis, pemrosesan data streaming, dan machine learning kini semakin mudah diakses dan diimplementasikan. Dengan memanfaatkan data cuaca real-time, data hari libur, serta histori penjualan, sebuah sistem prediksi pendapatan dapat dibangun untuk memberikan wawasan yang lebih akurat kepada pemilik usaha.

Berdasarkan latar belakang tersebut, proyek ini bertujuan untuk membangun sebuah sistem pipeline data end-to-end yang mengotomasi proses pengumpulan, pengolahan, dan analisis data untuk Warkop Kusuma Sukoharjo. Sistem ini diharapkan mampu menghasilkan prediksi pendapatan harian yang dapat membantu pemilik usaha dalam mengambil keputusan operasional yang lebih tepat, efisien, dan berbasis data.

1.2 Tujuan Proyek

1. Membangun sistem pipeline data otomatis yang mampu mengumpulkan, mengolah, dan menyimpan data cuaca harian, data hari libur nasional, serta data penjualan Warkop Kusuma Sukoharjo secara terintegrasi.
2. Mengimplementasikan pemrosesan data streaming secara real-time menggunakan Apache Kafka dan Apache Spark untuk memastikan data cuaca yang masuk dapat langsung diproses dan tersimpan tanpa keterlambatan.
3. Membangun model machine learning berbasis Random Forest yang mampu memprediksi pendapatan harian Warkop Kusuma berdasarkan fitur cuaca dan kalender seperti suhu, curah hujan, kelembaban, serta status hari libur.
4. Menyajikan hasil analisis dan prediksi pendapatan dalam bentuk dashboard interaktif menggunakan Metabase, sehingga pemilik usaha dapat memantau kondisi bisnis secara mudah dan real-time.

5. Mengintegrasikan sistem pemantauan pipeline menggunakan Prometheus, Loki, dan Grafana guna memastikan seluruh komponen sistem berjalan dengan stabil dan dapat dideteksi apabila terjadi gangguan.
6. Memberikan rekomendasi berbasis data kepada pemilik Warkop Kusuma sebagai bahan pertimbangan dalam pengambilan keputusan operasional sehari-hari.


1.3 Perancangan Arsitektur Pipeline (Indikator 1 - Bobot 10%)

1.3.1 Desain Arsitektur End-to-End

Sistem dirancang secara on-premise menggunakan kontainer Docker untuk mengintegrasikan pengolahan batch dan real-time stream. Berikut adalah diagram desain arsitektur end-to-end:


Langkah 1: Batch Processing Pipeline (Data Historis & Keuangan)

Fase ini menangani pengambilan data penjualan kasir secara offline (CSV) dan data cuaca historis/prakiraan dari Open-Meteo API ke PostgreSQL melalui Airflow.




Langkah 2: Real-time Streaming Pipeline (Kafka & PySpark)

Fase ini menangani pengambilan data cuaca secara langsung dari OpenWeatherMap API setiap 10 detik, dikirim ke antrean Kafka, lalu diproses secara streaming oleh Spark Structured Streaming dan disimpan ke PostgreSQL.




Langkah 3: Machine Learning Pipeline (Training & Inference)

Fase ini memproses data historis gabungan di database untuk melatih model regresi (Random Forest/Gradient Boosting) menjadi file .pkl serta memproyeksikan ramalan omzet warkop 14 hari ke depan.



Langkah 4: Serving & Business Intelligence (Metabase)

Fase akhir di mana semua tabel data analitik dan hasil prediksi pendapatan dipaparkan secara aman menggunakan akun database Read-Only ke dashboard Metabase untuk visualisasi pengguna akhir.



1.3.2 Peranan Komponen Arsitektur

- **Docker:** Mengkontenerisasi semua komponen yang dibutuhkan (kafka, zookeeper, Spark, dll)
- **Apache Airflow:** Sebagai orkestrator workflow batch dan stream.
- **Apache Kafka:** Sebagai message broker penampung data streaming cuaca.
- **Apache Spark (PySpark):** Sebagai processing engine untuk data streaming.
- **PostgreSQL:** Sebagai Data Warehouse penyimpanan utama semua data.
- **Metabase:** Sebagai alat visualisasi data (Business Intelligence).

BAB 2: HASIL DAN PEMBAHASAN

2.1 Implementasi Batch Processing (Indikator 2 - Bobot 10%)

2.1.1 Alur Kerja Pipeline Batch (ETL)

Pemrosesan data batch yang dijadwalkan oleh Apache Airflow meliputi:

1. **Pipeline Pendapatan Warkop (pendapatan_warkop_pipeline):**
 - **Sumber:** File CSV penjualan kasir yang diletakkan di /opt/airflow/data/raw/.
 - **Alur:** Membaca data, membersihkan format, melakukan agregasi omset harian per tanggal, dan mengunggahnya ke tabel pendapatan_harian di Postgres.
2. **Pipeline Kalender & Hari Libur (hari_libur_etl_pipeline):**
 - **Sumber:** Ketetapan hari libur nasional (SKB 3 Menteri) yang didefinisikan secara manual pada skrip Python.
 - **Alur:** Men-generate kalender lengkap satu tahun (mendeteksi weekend secara otomatis) dan memuatnya ke tabel hari_libur.
3. **Pipeline Cuaca Tambahan (cuaca_sukoharjo_sebulan_lalu_pipeline & cuaca_sukoharjo_prediksi_2minggu_pipeline):**
 - **Sumber:** Open-Meteo Archive & Forecast API.
 - **Alur:** Mengambil data cuaca batch (sebulan lalu & ramalan 14 hari) lalu mengunggahnya ke database.

2.1.2 Keandalan dan Idempotency

[Jelaskan bagaimana pipeline batch menangani masalah duplikasi data jika dijalankan ulang (misalnya dengan menggunakan perintah DELETE rentang tanggal sebelum melakukan INSERT atau query ON CONFLICT UPSERT pada PostgreSQL).]

2.2 Implementasi Stream Processing (Indikator 3 - Bobot 15%)

2.2.1 Arsitektur Streaming Real-Time (Kafka & PySpark)

Sistem memproses aliran data cuaca real-time dengan interval 10 detik sebagai berikut:

- **Kafka Producer** (kafka_producer_weather.py): Mengambil data cuaca Sukoharjo dari OpenWeatherMap API dan mempublikasikannya ke Kafka topic weather_stream setiap 10 detik .
- **Kafka Broker:** Menjadi antrean pesan streaming yang andal.
- **PySpark Structured Streaming** (pyspark_consumer_weather.py): Membaca streaming dari Kafka secara real-time, mengonversi skema JSON, melakukan pembersihan data (rounding desimal, pemetaan kode cuaca ke deskripsi teks), dan menyimpannya langsung ke database PostgreSQL (cuaca_historis).

2.2.2 Analisis Perbandingan Batch vs Stream

[Jelaskan analisis perbedaan antara pemrosesan batch dan stream di proyek ini dari segi latency, volume data, metode penyimpanan, dan teknologi yang digunakan.]

2.3 Integrasi Pipeline dengan Machine Learning (Indikator 4 - Bobot 15%)

2.3.1 Proses Pelatihan Model (Training Pipeline)

- **Model:** RandomForestRegressor / GradientBoostingRegressor.
- **Dataset:** Diambil dari view database SQL vw_dataset_ml yang menggabungkan histori omzet warkop, cuaca historis, dan kalender libur.
- **Output:** Model yang sudah terlatih diekspor menjadi file serialisasi model_prediksi_pendapatan.pkl.

2.3.2 Proses Prediksi (Inference Pipeline)

- **Mekanisme:** Skrip predict_to_postgres.py memuat file .pkl menggunakan pustaka joblib.
- **Input Fitur:** Prakiraan cuaca 14 hari ke depan (dari API) dikombinasikan dengan kalender libur mendatang.
- **Penyimpanan:** Hasil prediksi pendapatan harian diunggah ke tabel database prediksi_pendapatan untuk siap ditampilkan ke dashboard.

2.4 Visualisasi & Dashboard Analitik (Indikator 5 - Bobot 10%)

2.4.1 Desain Dashboard

Metrik-metrik bisnis yang disajikan di halaman dashboard Metabase:

- Total pendapatan mingguan/bulanan.
- Grafik korelasi curah hujan terhadap fluktuasi pendapatan.
- Grafik korelasi hari libur/weekend terhadap tingkat penjualan.
- Tabel proyeksi/prediksi pendapatan 14 hari ke depan untuk estimasi stok bahan baku.

2.4.2 Analisis Insight Bisnis Warkop Kusuma

[Tuliskan temuan atau wawasan penting yang dihasilkan dari visualisasi data cuaca dan omzet warkop Anda (contoh: "Penjualan turun drastis saat curah hujan melebihi 10mm di jam operasional sore hari").]

2.5 Sistem Monitoring, Logging & Alerting (Indikator 6 & 7 - Bobot 20%)

2.5.1 Mekanisme Monitoring & Logging

[Jelaskan sistem logging dan monitoring yang Anda pasang. Jika menggunakan Prometheus & Grafana untuk visualisasi performa kontainer, serta ELK Stack untuk sentralisasi log, deskripsikan cara kerjanya di sini.]

2.5.2 Sistem Notifikasi & Peringatan (Alerting System)

[Jelaskan bagaimana sistem memberikan notifikasi apabila terjadi kegagalan pipeline (misalnya notifikasi error Airflow ke Telegram/Discord, atau alert Grafana ketika resource CPU kontainer melebihi ambang batas).]

2.6 Keamanan Data (RBAC & Isolasi Jaringan) (Indikator 8 - Bobot 10%)

2.6.1 Isolasi Jaringan (Network Isolation)

Kontainer dipecah menjadi 3 Docker network terisolasi (orchestration-net, streaming-net, bi-net). Layanan luar seperti Metabase tidak bisa langsung mengakses antrian pesan Kafka.

2.6.2 Role-Based Access Control (RBAC)

- **Database RBAC:** Akun database Metabase dikonfigurasi menggunakan user khusus metabase_user yang bersifat Read-Only (hanya hak akses SELECT) untuk mencegah manipulasi data dari dashboard.
- **Airflow RBAC:** Membuat user tamu khusus dengan role Viewer (kredensial viewer / viewerpass) agar pihak luar dapat melihat DAG tanpa bisa mengeksekusi (trigger) atau merubahnya.

2.7 Tata Kelola Big Data (Data Governance) (Indikator 9 - Bobot 5%)

2.7.1 Pengecekan Kualitas Data (Data Quality)

[Jelaskan penerapan tata kelola data di proyek Anda, seperti penerapan pengecekan anomali data menggunakan pustaka Great Expectations (misalnya validasi tipe data atau penolakan data kosong/null).]

2.7.2 Data Lineage & Metadata

[Jelaskan bagaimana pelacakan asal-usul data dari API/CSV mentah hingga menjadi visualisasi di Metabase dipetakan dan diaudit di sistem Anda.]

BAB 3: PENUTUP

3.1 Kesimpulan

[Tuliskan kesimpulan akhir dari keberhasilan pembangunan infrastruktur Big Data dan manfaat prediksi pendapatan bagi Warkop Kusuma.]

3.2 Saran

[Tuliskan saran perbaikan infrastruktur untuk pengembangan sistem ke depan (misalnya migrasi ke arsitektur Cloud, peningkatan keandalan model ML, dll.).]

3.3 Dokumentasi Operasional & Reproducibility (Indikator 10 - Bobot 5%)

3.3.1 Panduan Instalasi dan Deployment

Untuk menjalankan sistem ini dari awal secara utuh, ikuti langkah berikut:

```
# 1. Kloning repositori
git clone [URL_REPO]
cd casebasedIPBD

# 2. Siapkan file .env dan masukkan API Key OpenWeatherMap Anda
echo "OPENWEATHERMAP_API_KEY=your_api_key_here" > .env

# 3. Jalankan seluruh container stack menggunakan Docker Compose
docker compose up -d --build

# 4. Inisialisasi database PostgreSQL RBAC

python scripts/scrapers/setup_db_rbac.py
```

3.3.2 Cara Menguji Pipeline Streaming

Untuk menguji pipeline cuaca real-time 10 detik:

4. Buka Airflow Web UI (<http://localhost:8080>) dan aktifkan serta jalankan DAG `kafka_spark_streaming_control` secara manual dengan sekali klik (Trigger DAG).
5. DAG tersebut akan otomatis menyalakan background Producer di kontainer Airflow, sekaligus mengirimkan perintah HTTP untuk menjalankan PySpark Structured Streaming Consumer secara otomatis di dalam kontainer Spark.
6. Pantau jalannya komputasi Spark streaming di browser: <http://localhost:4040> (Spark UI).
7. (Opsional) Anda juga dapat memantau log streaming secara langsung dari host machine di dalam folder `logs/spark_consumer.log` dan `logs/spark_consumer_err.log`.